



数值分析和优化算法

任课教师： 赵秀粉

2025年6月



1. 数据分析的概念

数据分析是指用适当的统计方法对收集来的大量第一手资料和第二手资料进行详细研究，提取有用信息和形成结论，以求最大化地**开发数据资料的功能与发挥数据的作用**。



2. 数据分析的方法

列表法

将实验数据按一定规律用列表方式表达出来是记录和处理实验数据最常用的方法。


作图法

作图法可以最醒目地表达物理量间的变化关系。从图线上还可以简便求出实验需要的某些结果（如直线的斜率和截距值等）。


2. 数据分析的方法

数据分析


因子分析
(Factor Analysis)



相关分析
(Correlation Analysis)




对应分析
(Correspondence Analysis)




回归分析
(Regression analysis)



方差分析
(ANOVA/Analysis of Variance)



聚类分析
(Cluster Analysis)



3. 数据分析的过程

数据分析的目的是利用数据来研究一个领域的具体问题。数据分析的过程包括**确定数据分析的目标、研究设计、收集数据、分析数据、解释结果。**



可以用量化分析根据数据解决特定领域问题。


利用数据分析方法进行计算和分析，以统计分析技术为主，借助各种软件工具。

优化设计的一般过程

进行实际工程问题优化设计的一般步骤：

- (1) 建立数学模型。
- (2) 选择最优化算法。
- (3) 程序设计。
- (4) 制定目标要求。
- (5) 计算机自动筛选最优设计方案等。

通常采用的最优化算法是逐步逼近法，有线性规划和非线性规划。



Matlab的特点及主要功能

- **MATLAB是一个交互式软件系统**，输入一条命令，立即就可以得出该命令的结果。
- **强大的数值计算功能**：矩阵为基本单位，动态定维；提供丰富的数值计算函数。
- **数据图示功能**：提供丰富的绘图命令，可实现点、线、面与立体的可视化操作。
- **编程功能**：具有程序结构控制、函数调用、数据结构等程序语言特征，简单易学、编程效率高。
- **Notebook功能**：实现Word和MATLAB无缝衔接。
- **丰富的工具箱**：工具箱是MATLAB的基本语句编成的各种子程序集，用于解决某一方面的专门问题或实现某一类新算法。

01 Matlab的工作界面

Matlab的工作界面


Matlab通用命令

命令	命令说明
clc	清除命令行窗口中的所有显示内容
clf	清除图形窗口
clear	清除工作区中的内存变量
whos	列出工作区中的变量的类型等信息
exit	退出MATLAB
quit	退出MATLAB

Matlab中的标点

标点	说明
:	冒号, 具有多种功能
;	分号, 区分行及取消运行结果显示
,	逗号, 区分列即参数分隔符
()	括号, 指定运算的优先级
[]	方括号, 定义矩阵
{}	大括号, 构造单元数组
%	百分号, 注释标记
!	惊叹号, 调用操作系统运算
=	等号, 赋值标记
'	单引号, 字符串的标识符
.	小数点及对象域访问
...	续行符号

MATLAB数据类型关系



04 Matlab的逻辑类型

Matlab的逻辑类型

布尔变量（也称逻辑变量）用于表示真（true）或假（false）的状态。使用logical数据类型，分别用数字1和0表示真和假。

```
a = true; % 创建逻辑真，显示为 1  
b = false; % 创建逻辑假，显示为 0
```

MATLAB还支持关系运算和逻辑运算，逻辑运算时把任何非零数值当做真，把零当做假。所有关系和逻辑表达式的输出：对于真，输出1；对于假，输出0。

逻辑类型数据进行运算时需要用到关系操作和逻辑运算符。

Matlab的关系操作符

关系操作符	说明
<	小于
<=	小于或等于
>	大于
>=	大于或等
==	等于
~=	不等于

=与==的
区别

04 Matlab的逻辑类型

Matlab逻辑运算符

逻辑运算符	说明
&	与， 符号两边都成立（非0） 结果才成立（1）
	或，符号两边有一侧为 非0结果就为1
~	非

逻辑运算符提供了一种组合或否定关系表达式。

(1) 变量

在程序执行过程中，其值可以被改变的量为变量。每一个变量需有一个变量名，它在内存中占有一个内存单元。Matlab中的变量可用来存放数据，也可用来存放向量或矩阵，并进行各种运算。

变量的命名规则是：①变量名区分字母大小写；②变量名以字母开头，可以由字母、数字、下划线组成，但不能使用标点；③变量名长度不超过63位，最多只能含有63个字符，后面的字符无效。

a=45 中 a为变量

(2) 永久变量

永久变量是变量的一种特殊情况，它在工作区中看不到，但是使用者可直接调用。常用的：

ans--用于保存结果的缺省变量名

pi--圆周率的近似值

eps—无穷小的近似值

inf—无穷大

i, j—虚数单位

Matlab的字符类型

Matlab字符类型

char类型表示一个字符或一维字符数组（字符串），用单引号括起来。

所有字符型变量都对应一个专门的代码（可以理解成键盘上的每一个字符都有一个专门的数值？）。

string：双引号括起来的。

在 MATLAB 中，**char** 类型表示一个字符或一维字符数组（字符串）。字符用单引号括起来，例如 `'A'` 或 `'Hello'` ¹。

创建和转换

可以使用单引号创建字符向量：

```
C = 'Hello, world'
```

如果有其他数据类型的数组，可以使用 `char` 函数将其转换为字符数组：

```
A = [77 65 84 76 65 66];  
C = char(A) % 结果为 'MATLAB'
```

`char` 函数还可以将多个数组转换为单个字符数组：

```
A1 = [65 66; 67 68];  
A2 = 'abcd';  
C = char(A1, A2)  
% 结果为：  
% 'AB '  
% 'CD '  
% 'abcd'
```

此外，`char` 函数可以将字符串转换为字符向量：

```
A = "Pythagoras";  
C = char(A) % 结果为 'Pythagoras'
```

Matlab的数值类型

Matlab数值类型

整数:

函数名	有无符号	占用字节	函数名	有无符号	占用字节
int8	有符号	1个字节	uint8	无符号	1个字节
int16	有符号	2个字节	uint16	无符号	2个字节
int32	有符号	4个字节	uint32	无符号	4个字节
int64	有符号	8个字节	uint64	无符号	8个字节

single: 单精度, 4个字节, 符号位第31位, 指数部分第30-23位, 小数部分第22-0位。

double: 双精度, 8个字节, 符号位第63位, 指数部分第62-52位, 小数部分第51-0位。默认数据类型

Matlab的数值类型

Matlab数值类型

整数:

```
>> a=3;  
>> b=int8(a);  
>> whos
```

Name	Size	Bytes	Class	Attributes
a	1x1	8	double	
b	1x1	1	int8	

int8范围在-128~127之间。

警惕数值超出范围。

```
>> a=150  
  
a =  
  
150  
  
>> b=int8(a)  
  
b =  
  
127
```

01 Matlab的数组类型

Matlab的数组类型

- 在MATLAB中进行运算的所有数据类型，都是按照数组和矩阵的形式存储和运算，二者在MATLAB中的运算性质不同，数组强调元素对元素的运算，而矩阵则采用线性代数的运算方式。本节主要介绍数组类型，矩阵会在后面的章节里讲到。
- 在MATLAB平台上，数组的定义是广义的，数组的元素可以是任意的数据类型，例如可以是数值、字符串、指针等

数组的创建

示例：利用[]直接创建数组，并把数组赋值给变量。

```
Array=[1 2 3 4 5 6]
```

```
Array =
```

```
1     2     3     4     5     6
```

Matlab的矩阵构造

- 对矩阵的基本操作，主要由矩阵的构造、矩阵维度与矩阵大小的改变、矩阵的索引、矩阵属性信息的获取、矩阵结构的改变等，
- 在数学上，定义有 $m \times n$ 个数 A_{ij} ($i=1,2,\dots,m, j=1, 2, \dots,n$) 排成的 m 行 n 列的数表为 m 行 n 列矩阵
- 只有一行的矩阵称为行向量
- 只有一列的矩阵称为列向量
- 矩阵和数组的联系：
- 在matlab中，矩阵是以数组的形式存在的。一维数组相当于向量，二维数组相当于矩阵，所以，矩阵是数组的子集。

建立简单的矩阵

示例：简单矩阵采用矩阵构造符号（方括号`[]`），将矩阵元素置于方括号内，同行元素之间用空格或者逗号隔开，行与行之间用分号（`;`）隔开。

```
A=[1,2,3;4 5 6]
```

```
A =
```

```
1     2     3
4     5     6
```

特殊矩阵的构建函数

函数名称

函数功能

- ones (n) 构建 $n \times n$ 的全1矩阵, 矩阵的元素全部是1
- ones (m,n) 构建 $m \times n$ 的全1矩阵
- ones (size(A)) 构建一个和矩阵A同样大小的1矩阵
- zeros (n) 0矩阵
- zeros (m,n)
- zeros (size(A))
- eye (n) 单位矩阵
- eye (m,n)
- eye(size(A))
- magic (n) 构建一个 $n \times n$ 的矩阵, 其每一行每一列的元素之和都相等
- rand (n) 构建一个 $n \times n$ 的矩阵, 其元素为0--1之间均匀分布的随机数
- rand (m,n) 构建一个 $m \times n$ 的矩阵, 其元素为0--1之间均匀分布的随机数

常用的矩阵索引表达式

索引表达式

函数功能

- $A(1)$ 将二维矩阵A重组为一维数组，返回数组中的第一个元素
- $A(:,j)$ 返回二维矩阵A中第j列列向量
- $A(i, :)$ 返回二维矩阵A中第i行行向量
- $A(:,j:k)$ 返回二维矩阵A中的第j列到第k列列向量组成的子矩阵
- $A(i:k,:)$ 返回二维矩阵A中第i行到第k行行向量组成的矩阵
- $A(i:k,j:l)$ 返回二维矩阵A中第i行到第k行行向量，和第j列到第l列列向量的交集组成的子矩阵
- $A(:)$ 将矩阵A中的每列合并成一个长的列向量
- $A(j:k)$ 返回一个行向量，其元素为 $A(:)$ 中的第j个元素到第k个元素
- $A([j1\ j2\ \dots])$ 返回一个行向量，其中的元素为 $A(:)$ 中的第j1, j2....个元素
- $A(:,j1\ j2\ \dots)$ 返回矩阵A中第j1, j2, ..列的列向量
- $A([i1\ i2\ \dots],:)$ 返回矩阵A中的第i1行, i2行。。。的行向量
- $A([i1\ i2\ \dots],[j1\ j2\ \dots])$ 返回矩阵第i1行, 第i2行。。。和第j1列, 第j2列等的元素

矩阵旋转与改变维度的函数

函数名称

函数功能

- `fliplr(A)` 矩形每一行均进行逆序排序, 也即左右翻转
- `flipud(A)` 矩阵每一列均进行逆序排列, 上下翻转
- `rot90(A)` 生成一个由矩阵A逆时针旋转90度而得到的新矩阵
- `rot90(A,k)` 生产一个由矩阵A逆时针旋转 $k \times 90$ 度而得到的新矩阵
- `reshape(A,m,n)` 生成一个 $m \times n$ 的矩阵, 其元素以线性索引的顺序从矩阵A中取得
A中元素个数必须为 $m \times n$ 个
- `reshape(A,[m n ...p])` 创建一个和矩阵A有相同元素的 $m \times n \times \dots \times p$ 多维元素
- `inv(A)` 矩阵A的逆

01 Matlab中的算术运算符

算术运算符

- **运算符：**

MATLAB中的运算符可以分为：
算术运算符、关系运算符
和逻辑运算符。

- **运算的优先级：**

算术运算符优先级最高，
其次是关系运算符，
最低级别是逻辑运算符

- **算术运算符：**

MATLAB中的运算符有加、减、
乘、除、点乘、点除等。
其运算法则见右：

算术运算符

算术运算符

- $A+B$

- $A-B$

- $A*B$

- $A.*B$

- A/B

- $A./B$

- A^B

- $A.^B$

运算法则

A与B相加，A、B为数值或矩阵

A与B相减，A、B为数值或矩阵

A与B相乘，A、B为数值或矩阵

A与B相应元素相乘，A、B为同维度的矩阵

A与B相除，A、B为数值或矩阵

A与B相应元素相除，A、B为相同纬度的矩阵

A的B次幂，A、B为数值或者矩阵

A的每个元素的B次幂，A为矩阵，B为数值

01 Matlab中的运算优先级

运算优先级

- 在一个表达式中，算术运算符优先级最高，其次是关系运算符，最后是逻辑运算符。需要时，可以通过加括号来改变运算顺序。

Matlab中具体的运算优先级排列如下表

优先级 运算法则

- 1 括号： $()$
- 2 转置和乘幂： $'$, $^$, $.^$
- 3 一元加减运算和逻辑非： $+$, $-$, $\sim$
- 4 乘除，点乘，点除： $*$, $/$, $.*$, $./$
- 5 冒号运算： $:$

优先级 运算法则

- 6 关系运算： $>$, $>=$, $<$, $<=$, $==$, $\sim =$
- 7 逐个元素的逻辑与： $\&$
- 8 逐个元素的逻辑或： $|$
- 9 捷径逻辑与： $\&\&$
- 10 捷径逻辑或： $\|\|$

01 Matlab的函数句柄

- 提高运行速度。因为matlab对函数的调用每次都是要搜索所有的路径，从set path中我们可以看到，路径是非常的多的，所以如果一个函数在程序中需要经常用到的话，使用函数句柄，对你的速度会有提高的。
- 使用可以与变量一样方便。比如说，在这个目录运行后，创建了一个本目录的函数句柄，当转到其他的目录下的时候，创建的函数句柄还是可以直接调用的，而不需要把那个函数文件拷贝过来。因为你创建的function handles中，已经包含了路径。
- 创建函数句柄的一般语法格式为：

Function_Handle=@Function_Filename;

- 其中：

Function_Filename是函数对应的M文件的名称或MATLAB内部函数的名称。

@是句柄创建操作符

Function_Handle变量保存了这一函数句柄，并在后续的运算中作为数据流进行传递。

04 Matlab的函数句柄

MATLAB系统提供了近20类基本命令函数，它们有一部分是MATLAB的内部命令，有一部分是以M文件形式出现的函数。

函数名	中文解释	函数名	中文解释	函数名	中文解释	函数名	中文解释
sin(x)	正弦函数	asin(x)	反正弦函数	abs(x)	绝对值或向量的长度	max(x)	最大值
cos(x)	余弦函数	acos(x)	反余弦函数	min(x)	最小值	sum(x)	元素求和
tan(x)	正切函数	atan(x)	反正切函数	sign(x)	符号函数	round(x)	四舍五入到最近的整数
exp(x)	以e为底的指数	log10(x)	以10为底数的对数	ceil(x)	朝正无穷方向取整	floor(x)	朝负无穷方向取整
log(x)	自然对数	sqrt(x)	开平方	fix(x)	朝零方向取整	gcd(x,y)	求两整数最大公约数

创建m文件

- 创建新的M文件，启动M文件编辑器方法如下：

(1) 在Matlab命令行窗口中运行指令 `edit`.

(2) 单击MATLAB界面工具栏或M文件编辑器工具栏的 “” 新建脚本图标。

(3) 选择MATLAB菜单栏的 “File” —— “New” —— “M文件” 选项。

变量名的正确命名：字母开头，由字母、数字或下划线组成。

循环语句

- Matlab 提供了两种循环方式： **for... end 循环**和**while... end 循环**
- **break**: 当某个条件满足时，使用break语句可以立即跳出循环。
- **continue**: 当前循环的某个迭代，继续执行下一个迭代。

条件控制语句

- Matlab 提供了多种条件控制方式：`if... else... end` 语句、`switch 分支结构`语句和其他流程控制语句（包括`continue`语句、`break`语句和`return`语句）

第

2

部分

数据描述性分析



什么是数据？

数据可以是连续的值，比如声音、图像，称为模拟数据。

模拟数据

数据也可以是离散的，如符号、文字，称为数字数据。


数字数据

数据(data)的诠释是事实或观察的结果，是对客观事物的逻辑归纳，是用于表示客观事物的未经加工的的原始素材。

1.数据的来源与分类

数据是数据分析的关键之一。数据也称观测值，是实验、测量、观察、调查等的结果，常以数量的形式给出。数据按照不同的标准进行分类，可分为：

- 1) 观测数据与试验数据
- 2) 一手数据与二手数据
- 3) 时间序列数据与横截面数据等。



数据描述性分析

数据描述性分析是从样本数据出发，概括分析数据的**集中位置、分散程度、相互关联关系**等，分析数据分布的**正态或偏态**特征。描述性分析是进行数据进一步分析的基础。对不同类型量纲的数据有时还要进行变换，然后再作出合理分析。本章主要介绍**样本数据的基本统计量、数据的可视化、数据分布检验及数据变换**等内容。

2.1 基本统计量与数据可视化

2.1.1 样本数据的基本统计量

描述数据基本特征主要为**集中位置**和**分散程度**。设从所研究的对象(即总体) X 中观测得到 n 个观测值：

$$x_1, x_2, \dots, x_n \quad (2.1.1)$$

这 n 个值称为**样本数据**，简称数据， n 称为**样本容量**。

我们的任务就是要对样本数据(2.1.1)进行分析，提取数据中所包含的有用的信息，从而进一步对总体的特性作出推断。

2.1 基本统计量与数据可视化

1 均值、中位数、分位数与三均值

$$m = \text{mean}(X)$$

数据 $(x_1, x_2, \dots, x_n)$ 的**平均值**称为该数据的均值，记为：

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \quad (2.1.2)$$

样本均值描述了数据取值的平均位置。样本均值计算简易，但易受异常值的影响而不稳健。

又将数据 (2.1.1) 按从小到大的次序排列，排序为 k 的数记为 $x_{(k)}$ ($1 \leq k \leq n$)，即 $x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}$ ，称：

$$x_{(1)}, x_{(2)}, \dots, x_{(n)} \quad (2.1.3)$$

为数据 (2.1.1) 的**次序统计量**。

2.1 基本统计量与数据可视化

1 均值、中位数、分位数与三均值

由次序统计量定义数M:

$$M = \begin{cases} x_{(\frac{n+1}{2})} & n \text{ 为奇数} \\ \frac{1}{2}(x_{(\frac{n}{2})} + x_{(\frac{n}{2}+1)}) & n \text{ 为偶数} \end{cases}.$$

MD=median(X)

(2.1.4)

称M为数据 (2.1.1) 的**中位数**。

中位数是描述数据的中心位置的数字特征，若数据的分布对称，则均值与中位数比较接近。若数据的分布为偏态，则均值与中位数差异会较大。中位数的一个显著特点是受异常值的影响较小，具有较好的稳健性。

2.1 基本统计量与数据可视化

1 均值、中位数、分位数与三均值

设 $0 \leq p < 1$ ，样本数据 (2.1.1) 的**p分位数**定义为：

$$M_p = \begin{cases} x_{([np]+1)} & np \text{不是整数} \\ \frac{1}{2}(x_{(np)} + x_{(np+1)}) & np \text{为整数} \end{cases} \quad (2.1.5)$$

$$SM = \text{prctile}(X, P)$$

其中 $[np]$ 表示 np 的整数部分。

显然，当 $p=0.5$ 时， $M_{0.5}=M$ ，即数据的0.5分位数等于其中位数。

一般来说，从整批数据（总体）中抽取样本数据，则整批数据中约有 $100p\%$ 个不超过样本数据的 p 分位。在实际应用中，**0.75分位数与0.25分位数**比较重要，它们分别称为**上、下四分位数**，记为 Q_3, Q_1 。

1 均值、中位数、分位数与三均值

样本均值用了数据的全部信息，M只用了部分信息，因此通常情况下，均值比中位数有效。另一方面，当数据有异常时，中位数比较稳健，为兼顾二者的优势，提出三均值的概念：

$$\hat{M} = \frac{1}{4}M_{0.25} + \frac{1}{2}M + \frac{1}{4}M_{0.75} \quad (2.1.6)$$

三均值是**上四分位数、中位数与下四分位数**的加权平均，即分位数向量 $(M_{0.25}, M, M_{0.75})$ 与权向量 $(0.25, 0.5, 0.75)$ 的内积。

```
w=[0.25,0.5,0.25];    %输入权向量w  
SM=w*prctile(X,w);    %由(2.1.6)式计算X三均值
```

2.1 基本统计量与数据可视化

2 方差与变异系数

方差是描述数据取值分散性的一种度量，它是数据相对于均值的偏差平方的平均。样本数据 (2.1.1) 的方差记为：

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{1}{n-1} \left(\sum_{i=1}^n x_i^2 - n(\bar{x})^2 \right) \quad (2.1.7)$$

其算术平方根称为**标准差**或根方差，即：

$$s = \sqrt{\frac{1}{n-1} \left(\sum_{i=1}^n x_i^2 - n(\bar{x})^2 \right)} \quad (2.1.8)$$

刻画数据 $x_1, x_2, \dots, x_n$ **相对分散性的指标**可以用**变异系数**，其计算公式为：

$$v = s / \bar{x}, \text{ 或 } s / |\bar{x}| \quad (2.1.9)$$

变异系数是一个无量纲的量，一般用百分数表示。

2.1 基本统计量与数据可视化

2 方差与变异系数

在MATLAB中，计算**方差**命令var，调用格式：

$$S = \text{var}(x)$$

计算**标准差**命令std，调用格式：

$$d = \text{std}(x)$$

其中输入x是样本数据，输出S为方差,d为标准差。当输入x是矩阵时，输出x每列数据的方差与标准差。

由均值与方差命令，可设计变异系数的计算程序为：

$$v = \text{std}(x) ./ \text{mean}(x) \text{ 或 } v = \text{std}(x) ./ \text{abs}(\text{mean}(x))$$

当输入x是矩阵时，输出x每**列**数据的变异系数。

2.1 基本统计量与数据可视化

3 样本的极差与四分位极差

极差是用来表示数据的分散性的数字特征，其最大值与最小值之间的差距，即最大值减最小值后所得之数据：

$$R = x_{(n)} - x_{(1)} \quad (2.1.10)$$

上、下四分位数 Q_3, Q_1 之差称为**四分位极差**，即：

$$R_1 = Q_3 - Q_1 \quad (2.1.11)$$

计算**极差**调用格式：**`max(data)-min(data)`**，或 **`range(data)`**

计算**四分位极差**调用格式：**`iqr(data)`**

4 异常点判别

先求上、下截断点： $R_{\text{上}} = Q_3 + 1.5R_1$ ， $R_{\text{下}} = Q_1 - 1.5R_1$
小于 $R_{\text{下}}$ 或大于 $R_{\text{上}}$ 的数据均为异常值。

P20, P22页代码

2.1 基本统计量与数据可视化

5 偏度与峰度

偏度是用于衡量分布的不对称程度或偏斜程度的指标。随机变量的偏度是变量的三阶中心矩除以标准差的三次方，计算样本的偏度公式为：

$$sk = \frac{n^2 b_3}{(n-1)(n-2)s^3}, \quad (2.1.12)$$

其中 b_3 , s 分别表示数据的3阶中心矩与标准差。

Matlab计算数据偏度的命令为: **skewness(data,0)**

正态分布的偏度为零，若 $sk > 0$ 称分布具有**正偏离**，也称右偏态，此时数据位于均值右边的数据比均值左边的数据更散，分布形状是右长尾；若 $sk < 0$ 称分布具有**负偏离**，也称左偏态，情况相反；而偏度接近0则可认为分布是对称的。若知道分布有可能在偏度上偏离正态分布时，可用偏离来检验分布的正态性。

2.1 基本统计量与数据可视化

5 偏度与峰度

峰度用来衡量数据尾部分散性，正态分布峰度为零，峰度 >0 ，则p平峰厚尾，峰度 <0 ，则尖峰细尾，在金融时间序列分析中，通常要研究数据是否为尖峰、细腰、厚尾等特性。随机变量的峰度是变量的四阶中心矩除以标准差的四次方，计算样本的峰度公式为：

$$ku = \frac{n^2(n+1)b_4}{(n-1)(n-2)(n-3)s^4} - \frac{3(n-1)^2}{(n-2)(n-3)}, \quad (2.1.13)$$

其中 b_4 , s 分别表示数据的4阶中心矩与标准差。

Matlab计算峰度的命令为：**kurtosis (data,0)-3** 。

2.1 基本统计量与数据可视化

2.1.2 样本数据可视化

1 可视化


数据可视化是指数据的图形表示。借助几何图形可形象说明数据的特征与分布情况。常用的图形有**条形图**、**直方图**、**盒图**、**阶梯图**和**火柴棒图**等。

(1) **条形图**。条形图是用宽度相同的直线条的高低或长短来表示统计指标数值的大小。

① **bar(X)**

② **bar(X,Y)**

①作样本数据X的条形图；② X的元素在横坐标轴上按从小到大排列，作Y和X对应的条形图。



2.1 基本统计量与数据可视化

1 可视化


(2) **直方图**。将观测数据的取值范围分为若干个区间，计算落在每个区间的频数或频率。在每个区间上画一个矩形，以估计总体的概率密度。

① `hist(x,n)`

作数据x的直方图，其中n表示分组的个数，缺省时n=10。

② `[h,stats] = cdfplot(x)`

作数据x的经验分布函数图，stats给出数据的最大值、最小值、中位数、平均值和标准差。



2.1 基本统计量与数据可视化


1 可视化

(3) **盒图**。盒图是由五个数值点组成：**最小值**，**下四分位数**，**中位数**，**上四分位数**，**最大值**。中间的盒子是从Q1延伸到Q3，盒子内的直线标示出中位数的位置，盒子两端有直线往外延伸到最小数与最大数，用作**显示一组数据分散情况资料**的统计图。

在MATLAB中，绘制盒图命令boxplot，调用格式：

boxplot(X)

产生矩阵X的每一列的盒图和“须”图，“须”是从盒的尾部延伸出来，并表示盒外数据长度的线，如果“须”的外面没有数据，则在“须”的底部有一个点。



2.1 基本统计量与数据可视化


1 可视化

(4) 阶梯图命令stairs, 调用格式


stairs(x)

(5) 火柴棒图命令stem, 调用格式

stem(x)



阶梯图



火柴棒图

2.1 基本统计量与数据可视化

2 二维与三维数据可视化

(1) 散点图，散点图是指在回归分析中，数据点在直角坐标系平面上的分布图，散点图表示因变量随自变量而变化的大致趋势，据此可以选择合适的函数对数据点进行拟合。

命令scatter与scatter3，调用格式：

`scatter(x,y)`

其中x是横坐标，y是纵坐标，输出平面散点图。

`scatter3(x,y,z)`

其中x,y,z分别是横、纵、竖坐标向量，输出空间散点图。

(2) 曲面图命令mesh与surf，调用格式

`mesh(X,Y,Z)`或`surf(X,Y,Z)`

2.1 基本统计量与数据可视化

3 正态概率图和Q-Q图

(1) 正态概率图。设总体服从正态分布 $N(\mu, \sigma^2)$ ，来自总体的样本为 $x_1, x_2, \dots, x_n$ ，其次序统计量 $x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}$ ，则X的经验分布函数为 $F_i = P\{X \leq x_{(i)}\}$ F_i 的估计值取为 $\hat{F}_i = \frac{i-0.375}{n+0.25}$ 。在平面上的 n 个点：

$$(x_{(i)}, \Phi^{-1}(\frac{i-0.375}{n+0.375}))(i=1,2,\dots,n) \quad (2.1.14 \text{ a})$$

的散点图称为正态概率图，横坐标是样本数据的分位图，纵坐标是相应的F值。这种坐标系也称为概率纸坐标系，可以证明，若样本来自正态总体，则正态概率图呈现一条直线形状。

2.1 基本统计量与数据可视化

3 正态概率图和Q-Q图

(2) Q-Q图。设总体服从正态分布 $N(\mu, \sigma^2)$ ，来自总体的样本为 $x_1, x_2, \dots, x_n$ ，其次序统计量 $x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}$ ，则平面上n个点：

$$(\Phi^{-1}(\frac{i-0.375}{n+0.375}), x_{(i)})(i=1, 2, \dots, n) \quad (2.1.14 \text{ b})$$

的散点图称为样本QQ图，其中 Φ^{-1} 为标准正态分布函数的反函数。

可以证明，若样本确是来自正态总体，则散点在直线附近，即QQ图大致呈现一条直线形状。当样本来自其它分布总体时，样本QQ图将是弯曲的。这样，利用QQ图可以直观地作正态性检验，即若QQ图近似一条直线时，则可认为样本数据来自正态总体。

2.1 基本统计量与数据可视化

3 正态概率图和Q-Q图

在MATLAB中，作正态概率图命令normplot，调用格式：

normplot(X)

其中输入X为向量时，显示正态概率图；当X为矩阵，则显示每一列的正态分布概率图形。

如果数据点基本散布在直线上，则表明数据服从该分布，否则拒绝该分布。

2.1 基本统计量与数据可视化

3 正态概率图和Q-Q图

在MATLAB中，绘制QQ图命令qqplot，调用格式：

`qqplot(X)`

`qqplot(X,PD)`

其中输入X为向量时，显示输入数据QQ图；当X为矩阵，则显示每一列的QQ图形。PD 是由fitdist命令指定的分布类，其调用方式为：

`PD=fitdist(X,distname)`

其中，distname是指定的分布类名称，常用有Beta（贝塔分布）、Binomial（二项分布）、Exponential（指数分布）、Normal（正态分布）、Weibull（威布尔分布）。qqplot中省略PD时默认为标准正态分布。

2.2 数据分布及检验

上一节中的数据直方图与Q-Q图等能直观粗略描述数据的分布，本节进一步研究如何判定数据是否服从正态分布的问题。若不服从正态分布，那么又可能服从怎样的分布？

2.2.1 一维数据分布检验

1 经验分布函数

设来自总体 X 的样本为 $x_{(1)}, x_{(2)}, \dots, x_{(n)}$ ，对于任意实数 x ，定义函数

$$F_n(x) = \begin{cases} 0, & \text{若 } x < x_{(1)}, \\ \frac{k}{n}, & \text{若 } x_{(k)} \leq x < x_{(k+1)}, \\ 1, & \text{若 } x \geq x_{(n)}. \end{cases} \quad (2.2.1)$$

称为**经验分布函数**。 $F_n(x)$ 表示事件 $\{X \leq x\}$ 在 n 次独立重复试验中的概率。

2.2 数据分布及检验

1933年, 格里汶科(Glivenko)证明了以下的结果: 对于任一实数 x , 当 $n \rightarrow \infty$ 时 $F_n(x)$ 以概率1一致收敛于分布函数, 即:

$$P\{\lim_{n \rightarrow \infty} \sup_{-\infty < x < \infty} |F_n(x) - F(x)| = 0\} = 1$$

这一结论表明: 对于任一实数 x , 当 n 充分大时

$$F(x) \approx F_n(x) \quad (2.2.2)$$

因此可用经验分布函数来近似代替 $F(x)$, 这一点也是由样本推断总体的最基本理论依据之一。

在MATLAB中, 作经验 (累积) 分布函数图形命令cdfplot, 调用格式:

- ① `cdfplot(X)` %作样本X的经验分布函数图形
- ② `h=cdfplot(X)` %h表示曲线的句柄
- ③ `[h,stats]=cdfplot(X)` %stats表示样本最小、大值、均值、中值与标准差

2.2 数据分布及检验

2 总体分布的正态性检验

(1) Jarque-Bera检验

Jarque-Bera检验简称JB检验，它是利用正态分布的偏度sk和峰度ku，构造一个包含sk、ku且自由度为2的卡方分布统计量。

$$JB = n\left(\frac{1}{6}J^2 + \frac{1}{24}B^2\right) \sim \chi^2(2)$$

$$\text{其中, } J = \text{sk} = \frac{1}{n} \sum_{i=1}^n \left(\frac{x_i - \bar{x}}{S}\right)^3, B = \text{ku} = \frac{1}{n} \sum_{i=1}^n \left(\frac{x_i - \bar{x}}{S}\right)^4 - 3$$

(2.2.3)

对于显著性水平 α ，当JB 统计量小于 χ^2 分布的 $1-\alpha$ 分位数 $\chi_{1-\alpha}^2(2)$ 时接受 H_0 ，即认为总体服从正态分布；否则拒绝 H_0 ，即认为总体不服从正态分布。这个检验适用于大样本，当样本容量n较小时需谨慎用。

在MATLAB中，JB检验命令jbtest，调用格式

$$[H,P,JBSTAT,CV] = \text{jbtest}(X,\alpha)$$

其中alpha是检验水平，通常取0.05，0.01，缺省默认为0.05。H为测试结果，若H=0，则无法拒绝正态分布；若H=1，则拒绝正态分布。

2.2 数据分布及检验

2 总体分布的正态性检验

(2) Kolmogorov-Smirnov检验

Kolmogorov-Smirnov检验简称KS检验，它是通过样本的经验分布函数与给定分布函数的比较，推断该样本是否来自给定分布函数的总体。设给定分布函数为 $G(x)$ ，构造统计量。

$$D_n = \max_n (|F_n(x) - G(x)|) \quad (2.2.4)$$

即两个分布函数之差的最大值，对于假设 H_0 ：总体服从给定的分布 $G(x)$ ，及给定的 α ，根据 D_n 的极限分布确定统计量关于是否接受 H_0 的数量界限。

因为这个检验需要给定 $G(x)$ ，所以当用于正态性检验时只能做标准正态检验，即 H_0 ：总体服从标准正态分布。

2.2 数据分布及检验

2 总体分布的正态性检验

(2) Kolmogorov-Smirnov检验

在Matlab中，KS检验命令kstest，调用格式

$h = \text{kstest}(x)$

$h = \text{kstest}(x, \text{cdf})$

$[h, p, \text{ksstat}, \text{cv}] = \text{kstest}(x, \text{cdf}, \alpha)$

把向量 x 中的值与标准正态分布进行比较并返回假设检验结果 h 。如果 $h=0$ 表示不能拒绝原假设，即不能拒绝服从正态分布。假设的显著水平默认值是0.05。 cdf 是一个两列矩阵，矩阵的第一列包含可能的 x 值，第二列式假设累积分布函数 $G(x)$ 的值，在可能的情况下， cdf 的第一列应包含 x 中的值，如果第一类没有，则用插值的方法近似。指定显著水平 α ，返回 p 值，K-S检验统计量 KSstat ；截断值 cv 。

2.2 数据分布及检验

2 总体分布的正态性检验

(3) Lilliefors检验

Lilliefors检验是改进K-S检验并用于一般的正态性检验，原假设 H_0 ：总体服从正态分布 $N(\mu, \sigma^2)$ ，其中 μ, σ^2 由样本均值和方差估计。

该检验的MATLAB命令lillietest，调用格式：

$[H,P,LSTAT,CV] = \text{lillietest}(X,\alpha)$

显著性水平 α 在0.01和0.2之间，缺省时为0.05。输出P为接受假设的概率值，LSTAT为测试统计量的值，CV为是否拒绝原假设的临界值。H为测试结果，若 $H=0$ ，则无法拒绝X是服从正态分布的；若 $H=1$ ，则可以否定X服从正态分布。

例2.2-2 41页

2.3 数据变换

2.3.2 Box-Cox变换

当数据在或右边左边有长尾巴，或很不对称时，有时需要对数据进行变换以符合非参数(或参数)统计推断方法的某些条件，其中最常用的一种方法就是box-cox变换：

$$y = \begin{cases} (x^\lambda - 1) / \lambda & \lambda \neq 0 \\ \log(x) & \lambda = 0 \end{cases} \quad (2.3.5)$$

在MATLAB中，上述变换的命令如下：

$$[t,l]=\text{boxcox}(x)$$

其中 x 是原始数据， t 是变换以后的数据， l 是变换公式中参数 λ 的数值。

第

3

部分

回归分析

人们经常需要研究两个或多个变量(现象)之间的相互(因果)关系, 并使用数学模型来加以描述和解释。如:

商品销售量与价格间的关系;


产品的某些质量指标与某些控制因素之间的关系;

家庭消费支出与家庭收入间的关系等等。

回归分析就是对变量间存在的**不确定关系**进行分析的统计方法。

1. 一元线性回归的基本概念

$$Y = \beta_0 + \beta_1 x + \varepsilon, \quad \varepsilon \sim N(0, \sigma^2)$$



Y 的分布呢?


一元线性回归分析的主要任务:

- ① 利用样本观测值 (x_i, y_i) , 估计回归系数 β_0 , β_1 和 σ ;
- ② 对方程的线性关系 (即 β_1) 是否为 0 作显著性检验;
- ③ 在 $x = x_0$ 处对 Y 作预测等。

2. 参数 β_0 , β_1 和 σ^2 的估计

最小二乘估计：要找一条直线，使：

$$\sum (y_i - \hat{y}_i)^2 = \min$$



2. 参数 β_0 , β_1 和 σ^2 的估计

利用最小二乘法可以得到回归模型参数 β_0, β_1 的最小二乘估计 $\hat{\beta}_0, \hat{\beta}_1$ 。

考虑残差平方和：

$$S(\beta_0, \beta_1) = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2 \quad (3.1.3)$$

当 $x_1, x_2, \dots, x_n$ 不全相等时，满足 $\min S(\hat{\beta}_0, \hat{\beta}_1)$ 的 $\hat{\beta}_0, \hat{\beta}_1$ 分别是 β_0, β_1 的最小二乘估计。

2. 参数 β_0 , β_1 和 σ^2 的估计

记 $S_E = \sum_{i=1}^n (y_i - \hat{y})^2$, 称为残差平方和, 可以证明 $\frac{S_E}{\sigma^2} = \frac{1}{\sigma^2} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \sim \chi^2(n-2)$, 因此参数 σ^2 的无偏估计为:

$$\hat{\sigma}^2 = \frac{S_E}{n-2}$$

因此, 在一元线性回归方程中需要表达的参数有:

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$$

$$\hat{\beta}_0 = \bar{y} - \bar{x}\hat{\beta}_1$$

$$\hat{\beta}_1 = L_{xy}/L_{xx}$$

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i; \quad \bar{y} = \frac{1}{n} \sum_{i=1}^n y_i;$$

$$L_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2 \neq 0, \quad L_{xy} = \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$

3.回归方程的显著性检验

通过参数估计得到回归方程后，还需要对回归方程进行检验，以确定变量间是否存在显著的线性关系。

对一元线性回归模型，如果变量 Y 与 X 之间并不存在线性相关关系，则模型中的一次项系数 β_1 应为0；反之，则 $\beta_1 \neq 0$ 。

故对一元线性回归模型，要检验的原假设为：

$$H_0: \beta_1 = 0$$

以上检验称为对回归方程的显著性检验。

3.回归方程的显著性检验

常用的检验方法有三种，分别为F检验（方差分析法）、T检验与可决系数 R^2 检验。

➤ 1) F检验（方差分析法）

Y 的观察值 $y_1, y_2, \dots, y_n$ 之间的差异是由两方面的原因引起的：

- (1) 自变量 X 的取值 x_i 不同；
- (2) 其他因素和试验误差的影响。

3.回归方程的显著性检验

➤ 1) F检验 (方差分析法)

为检验以上两方面中哪一个对 Y 取值的影响是主要的, 就需要将它们各自对 Y 取值的影响, 从 y_i 总的差异中分解出来。

考虑总的偏差平方和:

$$s_T = \sum (y_i - \bar{y})^2$$

来表示全部观察值 y_i 间总的差异量。将其分解如下:

$$s_T = \sum (y_i - \hat{y}_i)^2 + (\hat{y}_i - \bar{y})^2 = s_E + s_R$$

3.回归方程的显著性检验

$$s_T = \sum (y_i - \hat{y}_i)^2 + (\hat{y}_i - \bar{y})^2 = s_E + s_R$$

称 s_R 为**回归平方和**，它主要是由于变量 X 的取值不同引起的，其大小反映了 X 对 Y 影响的重要程度。

称 s_E 为**剩余平方和或残差平方和**，它主要由随机误差和其他因素的影响所引起。

3.回归方程的显著性检验

计算F值得过程如下方差分析表：

方差分析表

方差来源	平方和 (SS)	自由度	均方和	F值
回归	s_R	$f_R = 1$	$MS_R = s_R/f_R$	$F = \frac{MS_R}{MS_E}$
残差	s_E	$f_E = n - 2$	$MS_E = s_E/f_E$	
总计	s_T	$f_T = n - 1$	-	-

$$s_T = \sum_{i=1}^n (y_i - \bar{y})^2 = s_E + s_R, s_R = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2,$$

$$s_E = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = s_T - s_R。$$

3.回归方程的显著性检验

统计量:

$$F = \frac{S_R}{s_E / (n - 2)} \sim F(1, n - 2)$$

因此, 在给定显著性水平 α 下, H_0 的拒绝域为:

$$\{F \geq F_{1-\alpha}(1, n - 2)\}$$

并称回归方程是显著的, 可以用回归方程对 Y 进行预测或控制分析; 反之, 则称回归方程无显著意义。

3.回归方程的显著性检验

➤ 2) T检验

在 H_0 成立时, 取T统计量为:

$$T = \frac{\hat{\beta}_1}{\hat{\sigma}} \sqrt{l_{xx}} \sim t(n-2)$$

给定显著水平 α , H_0 的拒绝域为:

$$|T| > t_{\alpha/2}(n-2)$$

3.回归方程的显著性检验

➤ 3) 可决系数 R^2 检验

可决系数 R^2 的计算公式为：

$$R^2 = \frac{S_R}{S_T} = \frac{\sum (\hat{y}_i - \bar{y})^2}{\sum (y_i - \bar{y})^2}$$

在 H_0 成立时, $S_R = 0, R^2 = 0$ 。因此 R^2 越接近0, 方程越不显著; R^2 的值越接近1, 方程越显著, 也就是回归直线对观测值的拟合度越好。

4. 利用回归方程预测

若回归方程 $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$ 显著, 将其用于 Y 的预测。

在 $x = x_0$ 处 $Y = y_0$ 的回归预测值为:

$$\hat{y}_0 = \hat{\beta}_0 + \hat{\beta}_1 x_0$$

且:

$$\hat{y}_0 \sim N \left(\beta_0 + \beta_1 x_0, \left(\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{l_{xx}} \right) \sigma^2 \right)$$

y_0 的置信水平为 $1 - \alpha$ 的预测区间为 $[\hat{y}_0 - \delta, \hat{y}_0 + \delta]$, 其中

$$\delta = \delta(x_0) = t_{\frac{\alpha}{2}}(n-2)\hat{\sigma} \sqrt{1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{l_{xx}}}$$

1. 回归模型与回归系数估计

在一元回归模型中，如果变量 y 与 x 的关系是 n 次多项式，即：

$$y = p_1x^n + p_2x^{n-1} + \cdots + p_nx + p_{n+1} + \varepsilon$$

其中随机误差 $\varepsilon \sim N(0, \sigma^2)$ ， $p_1, p_2, \dots, p_n, p_{n+1}$ 为回归系数。上式称为多项式回归模型。

2. 多项式回归的MATLAB实现

➤ 1. 多项式曲线拟合

MATLAB统计工具箱，多项式曲线拟合命令polyfit，其调用格式有以下三种：

① $p = \text{polyfit}(x, y, n)$

x, y ——输入，样本观测数据向量

② $[p, S] = \text{polyfit}(x, y, n)$

n ——多项式的阶数

③ $[p, S, mu] = \text{polyfit}(x, y, n)$

p ——输出，系数向量

S ——用于估计预测误差的矩阵

mu —— x 的均值与标准差数组

2. 多项式回归的MATLAB实现

➤ 2. 多项式回归区间预测

多项式回归区间预测命令polyval，调用格式：

① $Y = \text{polyval}(p, x_0)$

② $[Y, \text{Delta}] = \text{polyval}(p, x_0, S, \alpha)$

p 、 S 是 $[p, S] = \text{polyfit}(x, y, n)$ 的输出， $1 - \alpha$ 为置信水平（ α 缺省时为0.05）， x_0 为自变量取值， Y 为预测值， Delta 为 Y 预测值的置信区间半径。

回归诊断主要包括三方面内容：

- ◆ 异常点与强影响点诊断；
 - ◆ 残差分析；
 - ◆ 多重共线性诊断。
-
- ◆ 多元回归残差图命令：rcoplot

01 优化设计的数学模型

- 优化设计的数学模型：以等式或不等式函数描述的约束条件和以多变量函数描述的优化设计目标。数学模型力求准确而简洁地反映工程问题的客观实际。
- 数学模型是对实际工程问题的数学描述，是优化设计的基础，是用数学语言来描述实际设计问题的设计条件与设计目标，是优化设计问题的抽象化描述。
- 过于强调准确或确切，往往会使数学模型十分冗长、复杂。片面强调简洁，则可能使数学模型失真。

建立数学模型的基本原则：在能够准确反映实际工程问题的基础上力求简洁。

01 优化设计的数学模型

1.1 设计变量 (Design Variable) 与设计空间

设计变量就是进行优化设计时所要确定的设计参数，它在优化设计过程中是不断变化的。通过其变化，使设计方案逐步趋近于最优方案。设计变量可以是几何参数（如形状、体积、位置等），也可以是物理参数（如力、速度、加速度等）。通常来说，一组设计变量取值确定后就代表着一个设计方案；一组值不相同的设计变量，就代表着不同的设计方案。

对于一个具有 n 个设计变量的优化设计问题，可以用一个 n 维列向量或列阵来表达：

$$X = [x_1, x_2, \dots, x_n]^T$$

一个设计点，即一个设计方案，也即向量 X 。

1.2 约束条件(Constraint condition)与可行域

1、约束条件

设计过程中的附加条件和对设计变量的某些限制就称为约束条件,用等式和不等式来表示 :

- 不等式约束条件(inequality constraints):

$$g_u(X) \geq 0 \quad \text{或} \quad g_u(X) \leq 0, u = 1, 2, \dots, m$$

- 等式约束(equality constraints) : $h_v(X) = 0, v = 1, 2, \dots, p < n$

- m 设计变量个数, m 不等式约束个数, p 等式约束个数


1. $p < n$

- 2.等式约束 $h_v(x)=0$ 可用两个不等式约束代替: $h_v(x) \geq 0$ 和 $-h_v(x) \leq 0$


01 优化设计的数学模型

2、可行域

由约束条件围成的区域，满足所有的约束条件故称为设计的**可行域**，此区域之外的任一点是全部或部分的不满足约束条件，故称为设计的**不可行域**。



不等式约束可行域



等式约束可行域

01 优化设计的数学模型


1.3 目标函数 (Objective Function) 与等值线 (面)

1. 目标函数

目标函数是以设计变量函数描述的优化设计目标，作为用来评价设计方案优劣的指标，在优化模型中目标函数十分关键，直接影响着优化设计的效果。表示为：

$$f(\mathbf{X}) = f(x_1, x_2, \dots, x_n)$$

- 根据优化设计所选定目标函数的个数，可将优化问题分为多目标优化问题与单目标优化问题。通常，多目标优化问题可经过加权组合后将其转化为单目标的优化问题来求解。
$$f(\mathbf{X}) = \sum_{i=1}^q W_i f_i(\mathbf{X})$$
- 如果是非线性函数，则优化问题为非线性优化问题；如果是线性函数，且约束函数也是线性函数，则优化问题为线性优化问题。



$$F(X) = x_1^2 + x_2^2 - 4x_1 + 4$$


2、目标函数等值线/面

在定义域内(在设计变量所构成的设计空间内), 目标函数值相同的点的集合或连线。

- 二维平面上相同目标函数值的所有点形成的曲线, 称为等值线;
- 三个设计变量的目标函数称为等值面;
- $n > 3$, 称为等值超曲面。

01 优化设计的数学模型

例：试画出约束优化问题的目标函数等值线和约束边界曲线。



$$\min f(x) = -4x_1 - x_2$$

$$s.t. \begin{cases} g_1(X) = x_1 - 6 \leq 0 \\ g_2(X) = -x_1 \leq 0 \\ g_3(X) = x_2 - 4 \leq 0 \\ g_4(X) = -x_2 \leq 0 \\ g_5(X) = x_1x_2 - 4 \leq 0 \end{cases}$$

01 优化设计的数学模型

1.4 优化的数学模型

在满足给定的约束条件下，选取适当的设计变量，使其目标函数达到最优值。其数学表达式为：

$$X = [x_1, x_2, \dots, x_n]^T \quad X \in D \subset E^n$$

在满足不等约束 $g_u(X) \leq 0, u = 1, 2, \dots, m$ 和等约束条件 $h_v(X) = 0, v = 1, 2, \dots, p$ 下，使目标函数 $f(X)$ 达到最优值。

•可简化为：

$$\begin{aligned} \min & f(X), X \in D \subset E^n \\ \text{s.t.} & \quad g_u(X) \leq 0, u = 1, 2, \dots, m \\ & \quad h_v(X) = 0, v = 1, 2, \dots, p \end{aligned}$$

最优点： $X^* = (x_1^*, x_2^*, \dots, x_n^*)^T$ 最优值： $f(X^*)$ ，合称最优解。

01 优化设计的数学模型

例 5.1-2 确定最优的分配方案，使产值最大。

	价值(万元)	煤	电	人工	煤: C吨 电: E度 人工: L个
A	P_A	a_C	a_E	a_L	
B	P_B	b_C	b_E	b_L	

解：设生产A、B两种产品分别为 x_1, x_2 ，该问题的优化数学模型为：

设计变量 $X = [x_1, x_2]^T$

目标函数 $\min f(X) = -(P_A x_1 + P_B x_2)$

约束条件
$$\begin{cases} g_1(X) = a_C x_1 + b_C x_2 - C \leq 0 \\ g_2(X) = a_E x_1 + b_E x_2 - E \leq 0 \\ g_3(X) = a_L x_1 + b_L x_2 - L \leq 0 \\ g_4(X) = -x_1 \leq 0 \\ g_5(X) = -x_2 \leq 0 \end{cases}$$

02 优化问题的极值条件

3. 一个约束起作用时极值点存在的必要条件：在 $X^{(k)}$ 可找到方向 $S^{(k)}$ 满足：


$$[-\nabla F(X^{(k)})]^T \bullet S^{(k)} > 0$$

$$[-\nabla g_u(X^{(k)})]^T \bullet S^{(k)} > 0 \quad u = 1, 2, \dots, J$$

$S^{(k)}$ 是可行的下降方向， $X^{(k)}$ 不是极值点。

在 X^* 点，约束函数与目标函数的等值线相切，目标函数的负梯度方向与约束函数的梯度方向重合。不能找到满足上式的方向。
点 X^* 为极值点。


$$-\nabla f(X^{(k)}) = \lambda \nabla g(X^{(k)}), \quad \lambda > 0$$



02 优化问题的极值条件

4. 两个约束起作用时极值点存在的必要条件

在 $X^{(k)}$ 点, 目标函数的负梯度方向 $-\nabla f(X^{(k)})$ 在向量 $\nabla g_1(X^{(k)})$ 和 $\nabla g_2(X^{(k)})$ 所组成的子空间
(所夹扇形区域) 外, 即存在方向 S 使目标函数即可行又下降。



$$-\nabla f(X^{(k)}) \cdot S^{(k)} > 0 \quad \text{保证下降性}$$

$$\nabla g_1(X^{(k)}) \cdot S^{(k)} < 0 \quad \text{保证可行性}$$

$$\nabla g_2(X^{(k)}) \cdot S^{(k)} < 0 \quad \text{保证可行性}$$

在 X^* 点, 目标函数的负梯度方向-

$-\nabla f(X^{(k)})$ 在向量 $\nabla g_2(X^{(k)})$ 和 $\nabla g_3(X^{(k)})$ 所组成的子空间内, 为局部极值点。

拉格朗日乘子

$$-\nabla f(X^{(k)}) = \lambda_2 \nabla g_2(X^{(k)}) + \lambda_3 \nabla g_3(X^{(k)}), \quad \lambda_2 > 0, \lambda_3 > 0$$

02 优化问题的极值条件

5. 约束极值点存在的必要条件——K-T条件

设计点 X^* ，该点处的各个起作用约束 $g_u(X^*) = 0 (u=1, 2, \dots, m)$ 的梯度向量为 $\nabla g_u(X^{(k)})$ ($u=1, 2, \dots, m$)，则 X^* 为约束极小点的必要条件是：

$$-\nabla f(X^{(k)}) = \lambda_1 \nabla g_1(X^{(k)}) + \nabla g_2(X^{(k)}) + \dots + \lambda_q \nabla g_q(X^{(k)}) = \sum_{i=1}^q \lambda_i \nabla g_i(X^{(k)})$$

式中， $\lambda_i > 0$ 是常数； $i=1, 2, \dots, q$ 为起作用约束个数。

K-T点的几何特征：一个约束作用；两个约束起作用；三个以上约束起作用（多棱锥体）

04 一维优化概述



4.1 一维优化概述

数值迭代算法的过程可表示为：

$$X^{(k+1)} = X^{(k)} + \alpha_k S^{(k)}$$

$$\min f(X^{(k+1)}) = \min f(X^{(k)} + \alpha_k S^{(k)}) = \min f(\alpha) = \min f(X^{(k)} + \alpha S^{(k)})$$

当搜索方向一定后，目标函数成为 α_k 的一元函数，即在直线上求函数的极小点，这种运算过程称为一维搜索，或线性搜索(Linear Search)。



04 一维优化概述

每步为一维搜索 $f(x^{k+1}) = f(x^k + \alpha_k d^k) = \varphi(\alpha_k) \rightarrow \min$

1) 解析法: $\varphi'(\alpha^*) = 0$

2) 数值解法的基本思想: 确定 α^* 所在的搜索区间, 然后根据区间消去原理不断缩小区间, 从而获得 α^* 的数值近似解。

$$f(X) \approx f(X^{(k)}) + \nabla f(X^{(k)})^T (X - X^{(k)}) + \frac{1}{2} (X - X^{(k)})^T \nabla^2 f(X^{(k)}) (X - X^{(k)})$$





$$f(X^{(K+1)}) = f(\alpha_k) \approx f(X^{(k)}) + \alpha_k \nabla f(X^{(k)})^T S^{(k)} + \frac{1}{2} \alpha_k^2 [S^{(k)}]^T \nabla^2 f(X^{(k)}) S^{(k)}$$


$$\alpha_k = -\frac{[\nabla f(X^{(k)})]^T S^{(k)}}{[S^{(k)}]^T \nabla^2 f(X^{(k)}) S^{(k)}}$$

05 外推法确定初始单谷区间

5.2 单谷区间的确定

外推法是确定单谷搜索区间的常用方法，是一种通过比较函数值大小来确定单峰区间的方法。已知一元函数 $f(a)$ ，假设在某搜索方向 S 上，以给定初始搜索步长 h ，从 a_0 出发沿着目标函数值下降的方向，逐步前进（或后退），直到找到相继的3个计算点的函数值出现“大→小→大”的趋势为止。





```

clear;
fun=@(x)x^2+2; %函数调用
h=0.5;        %步长用
a1=2;         f1=feval(fun,a1); %feval 求函数值
a2=a1+h;      f2=feval(fun,a2);

```

```

if(f1>f2)
    a3=a2+h;
    f3=feval(fun,a3);
else
    h=-h;
    a3=a1;  f3=f1;
    a1=a2;  f1=f2;
    a2=a3;  f2=f3;
    a3=a2+h;
    f3=feval(fun,a3);
end

```

```

while (f2>f3)
    a1=a2;  f1=f2;
    a2=a3;  f2=f3;
    a3=a2+2*h;
    f3=feval(fun,a3);
end

```

```

if a1>a3
    a=a3
    b=a1
else
    a=a1
    b=a3
end

```

06 黄金分割法

6.1 黄金分割法(Golden Section Method)

黄金分割法是通过不断缩短单峰区间的长度来搜索极小点的一种有效方法，它是搜索区间按比例缩小（**等比例的的直接搜索方法**），通过计算和比较函数值，以确定取舍区间（每次缩小后的区间长度与原长度之比为0.618），直至区间长度小于等于规定精度，从而得到最优解的数值近似解。因为每次缩小后的区间长度与原区长度之比为0.618，符合黄金分割原理，将其称为黄金分割法，又称为0.618法。

黄金分割是公元前六世纪古希腊数学家毕达哥拉斯所发现，后来古希腊美学家柏拉图将此称为黄金分割。

06 黄金分割法

6.2 区间消去法的基本原理


区间消去法是黄金分割法的基础，其基本原理是逐步缩小搜索区间，直至搜索区间范围达到要求的精度范围为止。假定区间缩小系数为 λ ，当 $0 < \lambda < 1$ ，对于任意的 ε ，总存在 N ，当 $n > N$ 时，有 $\lambda^n l \leq \varepsilon$ ，即用此方法可将单谷区间缩小到任意小，单谷区间两端足够靠近，则可认为找到极小值点。

在 $[a_1, a_3]$ 内对称的选择两个点 a_2, a_4 ，满足：

$$a_2 = a_3 - \lambda(a_3 - a_1)$$

$$a_4 = a_1 + \lambda(a_3 - a_1)$$

计算 f_2, f_4 ；区间变化图：



06 黄金分割法

6.3 区间缩小系数 λ 的确定

设原始区间 $[a_1, a_3]$ 的长度为1，在区间内取点 a_4 ，将区间分割成两部分，线段 $[a_1, a_4]$ 的长度记为 λ ，如图 (a) 所示，并满足


$$\frac{\lambda}{1} = \frac{1 - \lambda}{\lambda}, \quad \text{且 } \lambda > 1 - \lambda, \quad \text{解得 } \lambda = \frac{-1 \pm \sqrt{5}}{2},$$

舍去负值， $\lambda \approx 0.618$


λ 称为区间缩小系数，它表示每次缩小所得的新区间长度与缩小前区间长度之比，将黄金分割法应用于一维搜索时，在区间内取对称点 a_2 和 a_4 ，且满足： $\frac{\lambda}{1} = \frac{\lambda_1}{\lambda} = \frac{1 - \lambda}{\lambda}$

经过一次分割后，所保留的极值存在的区间要么是 $[a_1, a_4]$ ，

要么是 $[a_2, a_3]$ ，如图 (b) 所示。






(a)




(b)

06 黄金分割法

6.4 程序流程图





```

a1=0.6;
a3=2.4;
ep=0.2;
fun=@(x)2*x^2-5*x+9; %例5.6-1
lamd=0.618;
a2=a3-lamd*(a3-a1);f2=feval(fun,a2);
a4=a1+lamd*(a3-a1);f4=feval(fun,a4);

while(abs(a3-a1)>ep)
    if (f2>f4)
        a1=a2;f1=f2;
        a2=a4;f2=f4;
        a4=a1+lamd*(a3-a1);    f4=feval(fun,a4);
    else
        a3=a4;
        a4=a2;f4=f2;
        a2=a3-lamd*(a3-a1);    f2=feval(fun,a2);
    end
end

a_opti=(a3+a1)/2
f_opti=feval(fun,a_opti)
  
```

优化工具箱-optim

fminbnd:Single-variable bounded nonlinear function minization

fminbnd

Find minimum of single-variable function on fixed interval

[expand all in page](#)

Syntax

```
x = fminbnd(fun,x1,x2)
x = fminbnd(fun,x1,x2,options)
[x,fval] = fminbnd(...)
[x,fval,exitflag] = fminbnd(...)
[x,fval,exitflag,output] = fminbnd(...)
```

Description

fminbnd finds the minimum of a function of one variable within a fixed interval.

`x = fminbnd(fun,x1,x2)` returns a value `x` that is a local minimizer of the function that is described in `fun` in the interval `x1 < x < x2`. `fun` is a [function_handle](#).

[Parameterizing Functions](#) in the MATLAB® Mathematics documentation, explains how to pass additional parameters to your objective function `fun`.

`x = fminbnd(fun,x1,x2,options)` minimizes with the optimization parameters specified in the structure `options`. You can define these parameters using the `optimset` function. `fminbnd` uses these `options` structure fields:

例: `[x,fval_x]=fminbnd(@(x) 2*x^2-5*x+9,0.6,2.4)`

返回:`x=1.2500,fval_x=5.8750`


06 黄金分割法

黄金分割法 –总结

通过比较单峰区间内两个内分点的函数值，不断舍弃单峰区间的左端或者右端的一部分，使区间按照固定区间缩短率 ($\lambda=0.618$) 逐步缩短，直到极小点所在的区间缩短到给定的误差范围内，而得到近似最优解。

例：求 $f(x)=3x^2-8x+9$ 的极小点，给定单谷区间 $[0.6, 2.4]$, 收敛精度 $\varepsilon=0.2$ 。

6.1 概述



6.2 梯度法(Gradient Method)

一.基本原理

梯度方向是函数值变化率最大的方向：沿着梯度方向函数值上升最快；沿负梯度方向函数值下降最快。用负梯度方向作为搜索的方向，即：

$$s^{(k)} = -\nabla f(x^{(k)})$$

或用单位负梯度矢量来表示：

$$s^{(k)} = -\frac{\nabla f(x^{(k)})}{\|\nabla f(x^{(k)})\|}$$

因此，梯度法是用函数变化率最大的方向作为搜索方向，又称最速下降法。

二、迭代公式

$$x^{(k+1)} = x^{(k)} - \alpha_k \nabla f(x^{(k)}) \quad \text{或} \quad x^{(k+1)} = x^{(k)} - \alpha_k \frac{\nabla f(x^{(k)})}{\|\nabla f(x^{(k)})\|}$$

6.2 梯度法(Gradient Method)

式中，步长 α_k 可以任选，只要保证 $f(\mathbf{X}^{(k+1)}) < f(\mathbf{X}^{(k)})$ 。通常是沿负梯度方向进行一维搜索，找出其最优点作为下一步的迭代点。即：


$$\min_{\alpha} f(x^{(k)} - \alpha_k \nabla f(x^{(k)})) = f(x^{(k)} - \alpha_k \nabla f(x^{(k)}))$$

三、迭代过程及程序框图

四、练习

用梯度法求解 $f(\mathbf{X})=x_1^2+2x_2^2$ 的极小点。

设初始点 $\mathbf{X}^{(0)}=[1,1]^T$ ，要求迭代一次，求出下一轮的搜索方向，并验证相邻两次迭代的搜索方向互相垂直。



6.2 梯度法(Gradient Method)


五、梯度法特点

优点：程序简单，每次迭代所需的计算量小，贮存量也少；
对**初始点要求不高**，即使从一个不太好的初始点出发，往往也能收敛到局部极小点。

缺点：收敛的速度慢。

原因：最速下降是函数值在某一点的变化率而言，是一个**局部的性质**，从全局来看并不是最速下降方向。

因此梯度法的搜索路线呈直角锯齿形状，所得到的搜索点为绕道逼近最优点的，除非目标函数是圆
(例： $f(\mathbf{X})=x_1^2+x_2^2$ ， $\mathbf{X}^{(0)}=[2,2]^T$)。



6.6 惩罚函数法

6.6.2、内点罚函数法(Interior Penalty Function Method)

内点法适用于**不等式约束**，不能处理**等式约束**。

一、罚函数的构造

$$\phi(X, r^{(k)}) = f(X) - r^{(K)} \sum_{u=1}^m \frac{1}{g_u(X)}$$

或
$$\phi(X, r^{(k)}) = f(X) - r^{(K)} \sum_{u=1}^m \ln [-g_u(X)]$$

二、惩罚与逼近作用

◆当迭代点接近边界上时, $g_i(X) \approx 0$, $\frac{1}{g_i(X)} \rightarrow \infty$ 相当于在边界上设置了一道障碍, 或说是筑起了陡峭的围墙, 使迭代过程不得超越出去, 所以内点法也称**障碍函数法**或称为**围墙法**;

◆惩罚因子 $r^{(K)}$, 是递减的正数序列 $\lim_{K \rightarrow \infty} r^{(K)} = 0$;

◆点列 $\{X^*(r^{(K)})\}$ 逐渐趋于原目标函数的极值点。

6.6 惩罚函数法

例6.6.1 $\min f(X) = x, \quad x \in D$

$s.t. \quad g(X) = x - 1 \geq 0$

构造惩罚函数: $\phi(X, r^k) = x + r^k \frac{1}{x-1}$


$$\phi'(X, r^k) = 1 - \frac{r^k}{(x-1)^2} = 0$$

$$(x-1)^2 - r^k = 0$$

$$x^* = \sqrt{r^k} + 1$$

$$\phi(X(r^k), r^k) = 2\sqrt{r^k} + 1$$

$$r^{(k)} \rightarrow 0, \quad x^*(r^{(k)}) \rightarrow 1, \quad \phi \rightarrow 1$$



6.6 惩罚函数法

6.6.3、外点罚函数法(Exterior Penalty Function Method)

外点法特点是将惩罚函数定义于可行域外，且求解无约束问题的探索点是从可行域外部逼近原目标函数的最优解。

引例 $\min F(X) = ax$

$$x \in \mathfrak{R} \in R^n$$


$$s.t. \quad g_1(X) = -x + b \leq 0$$

在可行域外构建罚函数:

$$\phi(X, r^{(k)}) = \begin{cases} ax & x \geq b \\ ax + r^{(k)}(x-b)^2 & x < b \end{cases}$$

可写成另一种形式:

$$\phi(X, r^{(k)}) = ax + r^{(k)} \{ \max[0, (b-x)] \}^2$$



解析法求 $\phi(x, r^{(k)})$ 的极值点:

$$\frac{\partial \phi}{\partial x} = a + 2r^{(k)}(x-b) = 0$$

$$x^*(r) = b - \frac{a}{2r^{(k)}}$$

$$r^{(k)} \rightarrow \infty,$$

$$x^*(r^{(k)}) \rightarrow b,$$

$$\phi \rightarrow ab$$

6.6 惩罚函数法

一、外点罚函数的构型

对于仅有不等式约束的优化问题：

$$\phi(X, r^{(K)}) = f(X) + r^{(K)} \sum_{u=1}^m \left\{ \max[0, g_u(X)] \right\}^z$$

式中， z 为惩罚指数， $z=2$ ， $r^{(k)}$ 为惩罚因子，其取值为递增序列

$$0 < r^{(0)} < r^{(1)} < r^{(2)} < \dots < r^{(k)} < \dots$$

$$r^{(k)} = cr^{(k-1)} \quad c > 1$$

$$\lim_{k \rightarrow \infty} r^{(k)} = \infty$$

其中惩罚项

$$r^{(K)} \sum_{u=1}^m \left\{ \max[0, g_u(X)] \right\}^2 = \begin{cases} 0 & X \in \mathfrak{R} \\ r^{(K)} \sum_{u=1}^p \{g_u(X)\}^2 & X \notin \mathfrak{R} \end{cases}$$


$$\phi(X, r^{(k)}) = \begin{cases} f(X) + r^{(k)} \sum_{u \in I_1} [g_u(X)]^2 & X \notin \mathfrak{R} \\ f(X) & X \in \mathfrak{R} \end{cases}$$

I_1 为不满足约束条件的集合

6.6 惩罚函数法


二.惩罚与逼近的作用

1) 惩罚作用




2) 逼近作用

$r^{(k)} \rightarrow \infty$ 时, 只有 $g_u(X)=0$
才能使惩罚项减小, 从而
使惩罚函数减小。



6.6 惩罚函数法



6.6 惩罚函数法

例题6.6.2 $\min f(X) = (x-4)^2$


$$X \in D$$

$$D = \{x | x \geq 2\}$$

$$\begin{aligned}\phi(X, M^k) &= f(X) + M^k \left\{ \min[0, g_u(X)] \right\}^2 \\ &= (x-4)^2 + \begin{cases} 0, & \text{当 } x \geq 2 \\ M^k (x-2)^2, & \text{当 } x < 2 \end{cases}\end{aligned}$$

当可行域 $D = \{x | x \leq 2\}$

$$\begin{aligned}\phi(X, M^k) &= f(X) + M^k \left\{ \min[0, g_u(X)] \right\}^2 \\ &= (x-4)^2 + \begin{cases} 0, & \text{当 } x \leq 2 \\ M^k (x-2)^2, & \text{当 } x > 2 \end{cases}\end{aligned}$$



习题1、用黄金分割法求 $f(X)=x^2+2x$ 在区间 $-3\leq x\leq 5$ 上的极小值点，收敛精度 $\varepsilon=0.01$ 。（迭代一次）

习题2：用对数内点法求解有约束的优化问题：

$$\min f(\mathbf{x}) = x_1^2 + 6x_1 + x_2^2 + 4$$

$$s.t. x_1 \geq 0, x_2 \geq 0$$

习题3：用外点法求解有约束的优化问题

$$\min F(X) = x_1^2 + x_2^2 - x_1x_2 - 10x_1 - 4x_2 + 60$$

$$s.t. g(X)=x_1+x_2-8\leq 0$$

习题4：

用梯度法求解 $f(X)=x_1^2+2x_2^2$ 的极小点。设初始点 $X^{(0)}=[1,1]^T$ ，要求迭代一次，求出下一轮的搜索方向，并验证相邻两次迭代的搜索方向互相垂直。



感谢您的观看与聆听

任课教师：